

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN MÔN HỌC

Toán ứng dụng và thống kê

Giáo viên hướng dẫn: ThS. Võ Nam Thục Đoan
ThS. Lê Nhựt Nam

Nhóm thực hiện: Nhóm 14 – Lớp 24CTT2

Thành viên: 24120394 – Nguyễn Đặng Khôi Nguyên
24120331 – Lê Quốc Khải
24120384 – Phan Nhật Minh
24120370 – Trần Thị Lợi
24120474 – Trịnh Võ Triết

TP. Hồ Chí Minh, 2026

Contents

1	Phân Công Công Việc	2
2	CẤU TRÚC HỆ THỐNG VÀ CÁC MODULE	3
2.1	Cấu trúc thư mục	3
2.2	Cấu hình chung của hệ thống: <code>config.py</code>	3
2.2.1	Một số hình ảnh minh chứng	4
3	Phần 1: Lý Thuyết Data Fitting và Minh Họa	5
3.1	Bài Toán Data Fitting	5
3.1.1	Phát biểu bài toán tổng quát	5
3.1.2	Các Giả Thiết Gauss–Markov	5
3.2	Phương Pháp Ordinary Least Squares (OLS)	5
3.2.1	Hàm mất mát và nghiệm OLS	5
3.2.2	Ma Trận Chiều và Hat Matrix	6
3.2.3	Định Lý Gauss–Markov	6
3.2.4	Ước Lượng Phương Sai Nhiều	7
3.3	Đánh Giá Mô Hình	7
3.3.1	Hệ số xác định R^2 và $\bar{R}^2$ hiệu chỉnh	7
3.3.2	Kiểm Định Giả Thuyết	7
3.4	Các Vấn Đề Nâng Cao trong Data Fitting	7
3.4.1	Đa cộng tuyến (Multicollinearity)	7
3.4.2	Hồi Quy Ridge và Lasso (Regularization)	8
3.4.3	Phân Tích Phần Dư (Residual Analysis)	8
3.4.4	Cross-Validation và Lựa Chọn Mô Hình	8
3.5	Tiêu Chí Đánh Giá — Phần 1	9
	Tài Liệu Tham Khảo	10
A	Chi tiết kết quả chạy thuật toán Phần 1	11

1. Phân Công Công Việc

STT	Họ và tên	Nhiệm vụ phụ trách	Hoàn thành
1	Nguyễn Đăng Khôi Nguyễn (24120394)		100%
2	Lê Quốc Khải (24120331)		100%
3	Phan Nhật Minh (24120384)		100%
4	Trần Thị Lợi (24120370)		100%
5	Trịnh Võ Triết (24120474)		100%

2. CẤU TRÚC HỆ THỐNG VÀ CÁC MODULE

Mục này trình bày cấu trúc tổng thể của hệ thống, cách các Module được tổ chức và các thành phần dùng chung giữa phần 1 và phần 2.

2.1. Cấu trúc thư mục

```
Group_14/
|-- config.py                # Hằng số toàn cục (EPSILON,
    RANDOM_STATE)
|-- utils.py                 # Phép toán đại số tuyến tính tu đầu
|-- test_logger.py           # Tiện ích hỗ trợ xuất kết quả tính toán
|-- part1/
|   |-- ols_implementation.py # OLS, Hat matrix, VIF,...
|   |-- ridge_lasso.py        # Ridge, Lasso, Trace
|   |-- residual_analysis.py  # 4 biểu đồ chẩn đoán
|   |-- cross_validation.py   # k-Fold CV
|   |-- gauss_markov_demo.py  # Monte Carlo demo
|   |-- part1_notebook.ipynb  # Notebook tổng hợp kết quả
|   |-- test_case.py          # Chưa các unit test case
|-- part2/
|   |-- data/
|   |   |-- AirQualityUCI.csv # Dataset của dự án
|   |   |-- configs/
|   |   |   |-- *.json        # Cache kết quả CV và VIF
|-- output/
|   |-- *.json                # Lưu kết quả đánh giá và kiểm định
|   |-- data_pipeline.py      # Tiền xử lý, encoding, chuẩn hóa
|   |-- model_comparison.py   # Chạy huấn luyện mô hình và so sánh
|   |-- test_no_leakage.py    # Unit test chống rò rỉ dữ liệu
|   |-- advanced_methods.py   # Cài đặt Kernel và Bayesian
|-- report/
|   |-- report.pdf
|-- requirements.txt
```

2.2. Cấu hình chung của hệ thống: config.py

config.py là file cấu hình chung của toàn hệ thống. Nó định nghĩa các hằng số và hàm tiện ích được sử dụng xuyên suốt toàn bộ dự án.

- **RANDOM_STATE = 42:** Seed toàn cục đảm bảo tính tái lập của toàn bộ dự án từ sinh dữ liệu giả lập trong bởi các hàm hỗ trợ trong `utils.py`, Fisher-Yates shuffle trong `cross_validation.py`...
- **EPSILON = 1e-12:** Ngưỡng epsilon toàn cục. Mọi số có giá trị tuyệt đối nhỏ hơn ngưỡng này đều được coi là bằng 0 về mặt số học. Ngưỡng này được dùng nhất quán

trong tất cả phép chia, kiểm tra pivot, và tính VIF để tránh chia cho 0.

- `is_zero(x)`

2.2.1. Một số hình ảnh minh chứng

3. Phần 1: Lý Thuyết Data Fitting và Minh Họa

Tóm tắt yêu cầu Phần 1. Trình bày lại kiến thức đã học về data fitting và OLS. Với mỗi kết quả lý thuyết, sinh viên viết code Python để minh họa và kiểm chứng bằng dữ liệu giả lập (synthetic data).

3.1. Bài Toán Data Fitting

3.1.1. Phát biểu bài toán tổng quát

Định nghĩa 1.1 (Bài toán Data Fitting). Cho tập dữ liệu $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ với $\mathbf{x}_i \in \mathbb{R}^p$, $y_i \in \mathbb{R}$.

Bài toán data fitting là tìm hàm $f : \mathbb{R}^p \rightarrow \mathbb{R}$ trong một lớp hàm cho trước sao cho f xấp xỉ tốt nhất ánh xạ từ $\mathbf{x}_i$ đến y_i theo một tiêu chí đã định.

Trong mô hình **hồi quy tuyến tính**, ta giả thiết:

$$y_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_p x_{i,p} + \epsilon_i = \mathbf{x}_i^T \boldsymbol{\beta} + \epsilon_i \quad (3.1)$$

với $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^T \in \mathbb{R}^{p+1}$ là vector tham số cần ước lượng và ϵ_i là nhiễu ngẫu nhiên. Viết dưới dạng ma trận với $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$ (ma trận design có cột đầu toàn 1):

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon} \quad (3.2)$$

3.1.2. Các Giả Thiết Gauss–Markov

Các giả thiết Gauss–Markov (GM1 – GM5)

GM1. Tuyến tính: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$.

GM2. Không hoàn hảo đa cộng tuyến: $\text{rank}(\mathbf{X}) = p + 1$ (các cột độc lập tuyến tính).

GM3. Ngoại sinh: $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{0}$, tức $\mathbb{E}[\epsilon_i \mid \mathbf{x}_i] = 0$.

GM4. Đồng phương sai: $\text{Var}(\boldsymbol{\epsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n$, tức $\text{Var}(\epsilon_i) = \sigma^2$ và $\text{Cov}(\epsilon_i, \epsilon_j) = 0$ với $i \neq j$.

GM5. Phần dư Chuẩn: $\boldsymbol{\epsilon} \mid \mathbf{X} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$.

3.2. Phương Pháp Ordinary Least Squares (OLS)

3.2.1. Hàm mất mát và nghiệm OLS

OLS tìm $\hat{\boldsymbol{\beta}}$ tối thiểu hóa tổng bình phương phần dư (Residual Sum of Squares):

$$\text{RSS}(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = \sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2. \quad (3.3)$$

Định lý 1.1 (Nghiệm OLS — Normal Equations). Nếu $\mathbf{X}^T \mathbf{X}$ khả nghịch, nghiệm OLS duy nhất là:

$$\hat{\beta}_{\text{OLS}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}. \quad (3.4)$$

Chứng minh. Tính đạo hàm và cho đạo hàm bằng không:

$$\nabla_{\beta} \text{RSS} = -2\mathbf{X}^T (\mathbf{y} - \mathbf{X}\beta) = \mathbf{0}. \quad (3.5)$$

Suy ra hệ phương trình chuẩn:

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}. \quad (3.6)$$

3.2.2. Ma Trận Chiếu và Hat Matrix

Định nghĩa 1.2 (Hat Matrix). Ma trận chiếu (projection matrix hay hat matrix) là:

$$\mathbf{H} = \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \in \mathbb{R}^{n \times n}. \quad (3.7)$$

Mệnh đề 1.1 (Tính chất của $\mathbf{H}$).

- (i) $\mathbf{H}^2 = \mathbf{H}$ (idempotent).
- (ii) $\mathbf{H}^T = \mathbf{H}$ (đối xứng).
- (iii) Giá trị riêng của $\mathbf{H}$ chỉ là 0 hoặc 1.
- (iv) $\text{rank}(\mathbf{H}) = p + 1$.
- (v) Giá trị fitted: $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$; phần dư: $\hat{\mathbf{e}} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

3.2.3. Định Lý Gauss–Markov

Định lý 1.2 (Gauss–Markov). Dưới các giả thiết GM1–GM4, ước lượng OLS $\hat{\beta}_{\text{OLS}}$ là ước lượng tuyến tính không chệch tốt nhất (Best Linear Unbiased Estimator — BLUE):

- (i) **Không chệch:** $\mathbb{E}[\hat{\beta}_{\text{OLS}}] = \beta$.
- (ii) **Tốt nhất (phương sai nhỏ nhất):** Với mọi ước lượng tuyến tính không chệch $\tilde{\beta}$ khác, ta có $\text{Var}(\tilde{\beta}_j) \geq \text{Var}(\hat{\beta}_{j,\text{OLS}})$ với mọi j .

Ma trận hiệp phương sai của $\hat{\beta}_{\text{OLS}}$:

$$\text{Var}(\hat{\beta}_{\text{OLS}} | \mathbf{X}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}. \quad (3.8)$$

3.2.4. Ước Lượng Phương Sai Nhiễu

Ước lượng không chệch của σ^2 :

$$\hat{\sigma}^2 = \frac{\text{RSS}}{n - p - 1} = \frac{\|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2}{n - p - 1}. \quad (3.9)$$

3.3. Đánh Giá Mô Hình

3.3.1. Hệ số xác định R^2 và $\bar{R}^2$ hiệu chỉnh

Định nghĩa 1.3 (Hệ số xác định). Hệ số xác định R^2 được định nghĩa như sau:

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}, \quad R^2 \in [0, 1]. \quad (3.10)$$

R^2 luôn tăng khi thêm biến. Để so sánh các mô hình có số biến khác nhau, ta hay dùng R^2 hiệu chỉnh:

$$\bar{R}^2 = 1 - \frac{n - 1}{n - p - 1} (1 - R^2). \quad (3.11)$$

3.3.2. Kiểm Định Giả Thuyết

Dưới giả thiết chuẩn GM5:

$$\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}). \quad (3.12)$$

Kiểm định Student, t-test. Kiểm định ý nghĩa của từng đặc trưng đối với mô hình:

$$t_j = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{[(\mathbf{X}^T \mathbf{X})^{-1}]_{jj}}} \sim t_{n-p-1} \quad (H_0 : \beta_j = 0). \quad (3.13)$$

Kiểm định F cho mô hình tổng thể. Kiểm định ý nghĩa của mô hình:

$$F = \frac{(\text{TSS} - \text{RSS})/p}{\text{RSS}/(n - p - 1)} \sim F_{p, n-p-1} \quad (H_0 : \beta_1 = \dots = \beta_p = 0). \quad (3.14)$$

3.4. Các Vấn Đề Nâng Cao trong Data Fitting

3.4.1. Đa cộng tuyến (Multicollinearity)

Đa cộng tuyến xảy ra khi các cột của $\mathbf{X}$ có tương quan cao, khiến $\mathbf{X}^T \mathbf{X}$ gần suy biến. Để phát hiện hiện tượng này, ta có thể sử dụng hệ số phóng đại phương sai (Variance Inflation Factor):

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad (3.15)$$

trong đó R_j^2 là R^2 khi hồi quy biến X_j theo các biến còn lại. $\text{VIF} > 10$ cho thấy đa cộng tuyến nghiêm trọng.

3.4.2. Hồi Quy Ridge và Lasso (Regularization)

Khi dữ liệu có nhiều đặc trưng hoặc đa cộng tuyến, ta cần thêm thành phần chính quy hóa (regularization).

Ridge Regression (L2):

$$\hat{\beta}_{\text{ridge}} = \arg \min_{\beta} \{ \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2 \} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}. \quad (3.16)$$

Lasso Regression (L1):

$$\hat{\beta}_{\text{lasso}} = \arg \min_{\beta} \{ \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1 \}. \quad (3.17)$$

Lasso không có nghiệm closed-form; thường được giải bằng coordinate descent hoặc các phương pháp subgradient.

3.4.3. Phân Tích Phần Dư (Residual Analysis)

Sử dụng các công cụ thống kê mô tả để kiểm tra sai số của mô hình:

- **Residuals vs Fitted:** Kiểm tra tính tuyến tính và đồng phương sai.
- **Q-Q Plot:** Kiểm tra tính chuẩn của phần dư.
- **Scale-Location:** Kiểm tra phương sai đồng đều (homoscedasticity).
- **Cook's Distance:** Xác định các quan sát có ảnh hưởng lớn (influential points).

3.4.4. Cross-Validation và Lựa Chọn Mô Hình

k-Fold Cross-Validation. Chia dữ liệu thành k phần bằng nhau. Mỗi lần dùng $k - 1$ phần để huấn luyện, 1 phần để kiểm tra. Lặp k lần và lấy trung bình:

$$\text{CV}(k) = \frac{1}{k} \sum_{i=1}^k \text{MSE}_i. \quad (3.18)$$

Thông thường người ta lựa chọn mô hình dựa trên các tiêu chí như AIC (Akaike Information Criterion) hoặc BIC (Bayesian Information Criterion):

$$\text{AIC} = n \ln \left(\frac{\text{RSS}}{n} \right) + 2(p + 2), \quad \text{BIC} = n \ln \left(\frac{\text{RSS}}{n} \right) + (p + 2) \ln n. \quad (3.19)$$

3.5. Tiêu Chí Đánh Giá — Phần 1

Tiêu chí	Mô tả	Điểm
Trình bày lý thuyết OLS	Đúng, đầy đủ công thức, có chứng minh	1.0
Cài đặt OLS từ đầu	Đúng, kiểm chứng với NumPy	1.0
Hat matrix và tính chất	Cài đặt, kiểm tra idempotent	0.5
Kiểm định hệ số (t , F)	Tính đúng t-stat, p-value	0.5
Regularization (Ridge/Lasso)	Cài đặt, vẽ ridge trace	1.0
Phân tích phần dư	4 biểu đồ đầy đủ, nhận xét	0.5
Cross-validation	Cài k-fold CV, so sánh mô hình	0.5
Mình họa Gauss–Markov	Monte Carlo rõ ràng, nhận xét	0.5
Trình bày Notebook	Rõ ràng, có markdown giải thích	0.5
Tổng Phần 1		6.0

Tài Liệu Tham Khảo

1. Gilbert Strang. *Introduction to Linear Algebra*, 6th ed. Wellesley-Cambridge Press, 2023.
2. Lloyd N. Trefethen & David Bau III. *Numerical Linear Algebra*. SIAM, 1997.
3. Gene H. Golub & Charles F. Van Loan. *Matrix Computations*, 4th ed. Johns Hopkins University Press, 2013.
4. Cleve Moler. *Numerical Computing with MATLAB*. SIAM, 2004.
5. Manim Community Developers. *Manim – Mathematical Animation Framework*, v0.18. 2024.

A. Chi tiết kết quả chạy thuật toán Phần 1

Dưới đây là các hình ảnh minh họa chi tiết cho từng trường hợp đặc biệt khi chạy các thuật toán lỗi.